

Benchmark de Modelos de Linguagem Locais e Decisão de Modelo para o Projeto de Gestão e Interpretação de Documentos com IA

1. Objetivo

Este relatório documenta o processo de comparação entre dois modelos de linguagem (LLM) executáveis localmente, com o objetivo de selecionar o modelo generativo a ser utilizado na etapa de desenvolvimento do sistema de Recuperação Aumentada por Geração (RAG) do projeto de gestão e interpretação de documentos com IA para a AKAER. A avaliação considerou tempo de resposta, consumo de memória e — de forma central — a aderência dos modelos aos requisitos de confiabilidade e rastreabilidade definidos formalmente pelo cliente durante o levantamento de requisitos.

A tarefa original definida para esta etapa foi: “Comparar dois modelos locais, escolher qual vamos usar e anotar o tempo de resposta e o consumo de memória.” Este documento amplia essa tarefa, complementando as métricas quantitativas com uma avaliação qualitativa de groundedness (fidelidade ao contexto fornecido), por se tratar do critério explicitamente priorizado pelo cliente.

2. Contexto e Requisitos do Cliente

O levantamento de requisitos realizado com a AKAER estabeleceu condições que impactam diretamente a escolha do modelo de linguagem, das quais destacam-se três:

- Restrição de infraestrutura: os documentos não podem ser processados por serviço externo, de modo que todo o processamento — incluindo a geração de respostas por IA — deve ocorrer localmente, descartando o uso de modelos via API de terceiros.
- Separação obrigatória entre fato e interpretação: toda resposta gerada pela IA deve apresentar, de forma distinta, a informação extraída dos documentos, a interpretação da IA e os trechos/documentos utilizados como fonte.
- Prioridade de confiabilidade sobre velocidade: conforme resposta formal do cliente, “mais importante do que respostas instantâneas é garantir que sejam confiáveis, fundamentadas e rastreáveis”.

Esses três pontos nortearam o desenho da metodologia de teste descrita a seguir, priorizando cenários que avaliassem diretamente a capacidade de cada modelo de cumprir esses requisitos, e não apenas seu desempenho bruto.

3. Metodologia

3.1 Ambiente de execução

- Execução local via Ollama 0.34, sem uso de GPU dedicada (inferência 100% em CPU), simulando o cenário mais restritivo de hardware previsto para a fase de desenvolvimento (máquina de 8 GB de RAM).

- Modelos avaliados em formato GGUF, quantização Q4_K_M (padrão de distribuição do Ollama para a faixa de parâmetros testada).
- Medição de tempo via cronometragem da chamada à API local do Ollama (endpoint /api/generate); medição de memória via monitoramento do uso total de RAM do sistema e validação cruzada com o comando ollama ps.

3.2 Modelos avaliados

- Llama 3.2:3b — família Meta, ~2,6 GB carregado em memória.
- Qwen2.5:3b-instruct — família Alibaba, ~2,2 GB carregado em memória.

A escolha da faixa de 3 bilhões de parâmetros decorre da restrição de hardware da fase de desenvolvimento (8 GB de RAM), sendo esta uma decisão deliberada de reduzir o tamanho do modelo em relação a candidatos maiores (7-8B) inicialmente cogitados, permitindo viabilizar o desenvolvimento local do pipeline sem comprometer a máquina de trabalho. Ressalta-se que o modelo definitivo de produção poderá ser reavaliado após definição da configuração do servidor final do cliente.

3.3 Bateria de testes

Foram conduzidos quatro testes, divididos em duas categorias:

Teste 1 — Desempenho base (LLM pura, sem contexto documental)

Execução de um prompt simples, sem contexto de RAG, repetido em 5 execuções por modelo, medindo tempo de resposta e variação de memória. Objetivo: estabelecer linha de base de desempenho puro dos modelos.

Teste 2 — Contradição normativa explícita

Contexto simulado com dois documentos técnicos (domínio: compatibilidade de materiais aeroespaciais — alumínio 7050-T7451 e aço inoxidável 17-4PH) apresentando posições diretamente opostas: um documento de 2019 permitindo contato sob condição, e um boletim de engenharia de 2023 proibindo o contato de forma absoluta. Objetivo: verificar se o modelo reconhece a contradição sem tentar resolvê-la de forma não fundamentada.

Teste 3 — Pergunta fora do escopo dos documentos

Contexto com dois documentos técnicos que não respondem à pergunta feita (torque de aperto de parafusos, não coberto pelos documentos de passivação e rastreabilidade fornecidos). Objetivo: verificar se o modelo admite insuficiência de informação em vez de recorrer a conhecimento de treinamento não verificável.

Teste 4 — Conflito numérico sutil entre revisões do mesmo documento

Contexto com duas revisões da mesma especificação técnica de anodização, divergindo em valores numéricos de espessura mínima e máxima. Objetivo: verificar se o modelo mistura indevidamente os valores das duas fontes ao invés de reportá-los distintamente.

Em todos os testes com contexto documental, foi utilizado um prompt de sistema fixo exigindo a estruturação da resposta em três blocos: (1) informações encontradas nos documentos, (2) interpretação da IA, e (3) documentos e trechos utilizados como fonte — refletindo diretamente o requisito formal do cliente.

4. Resultados Quantitativos

Métrica	Llama 3.2:3b	Qwen2.5:3b-instruct	Observação
Tempo médio — prompt simples	10,89 s ($\pm 0,52$)	7,56 s ($\pm 1,42$)	Qwen ~30% mais rápido
Tempo médio — prompt com contexto documental	≈ 29 s	≈ 21 s	Qwen mais rápido também com contexto maior
Memória carregada (ollama ps)	$\approx 2,6$ GB	$\approx 2,2$ GB	Qwen mais leve em disco/RAM
Estabilidade do tempo de resposta	Consistente	Variável sob concorrência de CPU	Qwen apresentou maior desvio padrão em cenários com outros processos ativos

Observa-se que o Qwen2.5:3b apresentou desempenho superior em todas as métricas quantitativas — menor tempo de resposta (tanto em prompt simples quanto com contexto) e menor consumo de memória. Entretanto, também apresentou maior variação de tempo em cenários com concorrência de CPU (por exemplo, com o navegador aberto durante o teste), sugerindo menor previsibilidade de desempenho fora de condições controladas.

5. Resultados Qualitativos

Critério avaliado	Llama 3.2:3b	Qwen2.5:3b-instruct
Teste 1 — Contradição normativa explícita (proibição total vs. permissão condicional)	Reconheceu o conflito e não tentou resolvê-lo sozinho	Inventou reconciliação inexistente entre as fontes, criando exceção não prevista em nenhum documento
Teste 2 — Pergunta fora do escopo dos documentos	Admitiu corretamente a insuficiência de informação; manteve o formato de três blocos	Conteúdo correto, porém abandonou completamente o formato de três blocos exigido
Teste 3 — Conflito numérico sutil entre revisões do mesmo documento	Identificou os dois valores sem misturá-los; recomendou cautela	Não misturou valores, mas manteve inconsistência de formato e de citação

Critério avaliado	Llama 3.2:3b	Qwen2.5:3b-instruct
Aderência ao formato de citação em 3 blocos (nos 3 testes com contexto)	Consistente nos três testes	Falhou em 2 dos 3 testes

5.1 Achado crítico — Teste 2

O achado mais relevante da bateria de testes ocorreu no Teste 2. Diante de dois documentos em contradição direta (um permitindo contato entre materiais sob condição, outro proibindo de forma absoluta), o Llama reconheceu a existência do conflito e declarou explicitamente não ser possível fornecer resposta definitiva, recomendando consulta a especialistas — comportamento alinhado ao requisito de que a IA não deve substituir a decisão de um profissional responsável em assuntos críticos.

O Qwen, por sua vez, produziu uma resposta que combinava trechos das duas fontes de forma indevida, apresentando uma condição de uso (anodização) como se fosse compatível com o documento mais recente — que, na realidade, proíbe o contato “independentemente de tratamento superficial”. O modelo criou, portanto, uma exceção inexistente em qualquer um dos dois documentos fornecidos. Em um cenário real de uso pelo cliente, essa resposta poderia induzir a uma decisão de engenharia baseada em uma norma já revogada, com risco de falha estrutural por corrosão galvânica — justamente o cenário que o documento mais recente busca prevenir.

5.2 Aderência ao formato de rastreabilidade

Nos Testes 3 e 4, o Qwen não repetiu o erro de mesclar informações indevidamente, mas deixou de seguir integralmente a estrutura de três blocos exigida pelo prompt de sistema — no Teste 3, a resposta foi correta em conteúdo, porém sem qualquer formatação em blocos. Essa inconsistência é significativa para o projeto porque a estrutura de resposta não é uma preferência estética: trata-se do mecanismo definido para permitir a separação automatizada entre fato, interpretação e fonte, exigida contratualmente pelo cliente. Um modelo que abandona esse formato de forma inconsistente compromete a confiabilidade de qualquer processamento automatizado posterior da resposta.

6. Decisão e Justificativa

Modelo selecionado: Llama 3.2:3b

Optou-se pelo Llama 3.2:3b em detrimento do Qwen2.5:3b-instruct, apesar deste último apresentar desempenho quantitativo superior (aproximadamente 30% mais rápido e com menor consumo de memória). A decisão baseia-se no critério de priorização definido formalmente pelo cliente:

“Mais importante do que respostas instantâneas é garantir que sejam confiáveis, fundamentadas e rastreáveis.” — AKAER, levantamento de requisitos, Rodada 1.

Nos testes conduzidos, o Llama demonstrou comportamento consistente de reconhecer os limites da própria interpretação diante de contradições normativas, evitando reconciliações não fundamentadas, e manteve aderência ao formato de citação exigido em todos os cenários testados. O Qwen, apesar de mais rápido, apresentou uma falha crítica de groundedness no Teste 2 (invenção de reconciliação normativa inexistente) e inconsistência de formato em dois dos três testes com contexto documental — riscos que se sobrepõem ao ganho de desempenho observado, dado o domínio documental técnico-normativo do projeto.

7. Limitações e Próximos Passos

- O tempo de resposta em cenários com contexto documental (29-45 segundos) está acima da expectativa de “resposta próxima de uma pesquisa convencional” relatada pelo cliente, devendo ser tratado como item de atenção na etapa de otimização (ex.: técnicas de streaming de resposta, reranking para reduzir contexto enviado ao modelo, ou avaliação de hardware com aceleração por GPU).
- Os testes qualitativos utilizaram contexto documental simulado, elaborado com base no domínio técnico de materiais aeroespaciais já dominado pela equipe, dada a indisponibilidade dos documentos oficiais da AKAER até o momento da execução deste benchmark. Recomenda-se repetição dos testes com documentos reais assim que disponibilizados pelo cliente.
- A avaliação qualitativa foi realizada por leitura manual das respostas, não havendo, até o momento, processo automatizado de avaliação (ex.: uso de um segundo LLM como avaliador). Recomenda-se considerar essa abordagem para escalar a avaliação a um número maior de casos de teste.
- O modelo escolhido nesta etapa (Llama 3.2:3b) refere-se à fase de desenvolvimento em ambiente restrito de hardware (CPU-only, 8 GB de RAM). A escolha do modelo definitivo de produção deverá ser revalidada após definição da configuração de servidor do cliente, podendo incluir candidatos de maior porte caso hardware com GPU esteja disponível.
- Está prevista, em etapa complementar de aprendizado de máquina do projeto, a avaliação de fine-tuning do modelo de embedding utilizado na etapa de recuperação (retrieval) do pipeline RAG, de forma independente da escolha do modelo generativo aqui documentada.